

基于多模态声学特征的鸟类鸣声识别研究

骆俊杰¹

(1. 南京师范大学计算机与电子信息学院/人工智能学院, 江苏省南京市 210023)

摘要: 鸟类鸣声识别 (Bird Sound Recognition) 是生物声学 (Bioacoustics) 与环境智能监测的重要分支。从信号处理与语音识别的视角审视, 该任务可归结为非平稳、非语义、强噪声条件下的短音频分类问题。本报告围绕课程任务, 在 BirdCLEF 风格鸟鸣数据集上完成如下工作: (1) 设计并实现涵盖时域、频域、倒谱域、音高域与节奏域的多维声学特征提取方案, 并结合 Mel 对数谱图构建深度模型输入; (2) 系统对比经典传统机器学习方法与多种深度学习架构; (3) 提出 StitchedFusionNet 模块缝合网络, 在共享卷积骨干上并行融合 CNN 全局表征、CRNN 时序注意力与 Mamba 长程建模, 并以门控机制实现自适应加权; (4) 采用 Stacking 二级集成融合深度模型与 SVM 的异构判别信息。实验结果表明: 在 10 类快速对比设定下, Stacking (CNN + SVM) 验证集准确率达 85.5%, Macro- F_1 为 85.5%, Top-5 准确率达 98.8%; 扩展至 37 类后, Stacking (Hybrid + SVM) 仍保持 82.7% 准确率与 97.4% Top-5 准确率, 说明所构建的多模态特征与集成策略具有较好的可扩展性。

关键词: 鸟类鸣声识别; Mel 频谱; MFCC; 深度学习; 模块缝合; Stacking 集成; 生物声学

Research on Bird Sound Recognition Based on Multimodal Acoustic Features

Junjie Luo¹

(1. School of Computer and Electronic Information / School of Artificial Intelligence, Nanjing Normal University, Nanjing, Jiangsu 210023, China)

Abstract: Bird Sound Recognition is a crucial branch of bioacoustics and environmental intelligent monitoring. From the perspective of signal processing and speech recognition, this task can be formulated as a short audio classification problem under non-stationary, non-semantic, and high-noise conditions. This report conducts comprehensive work on a BirdCLEF-style dataset: (1) designing a multi-dimensional acoustic feature extraction scheme spanning time, frequency, cepstral, pitch, and rhythm domains; (2) systematically evaluating traditional machine learning methods and advanced deep learning architectures; (3) proposing StitchedFusionNet, which integrates CNN, CRNN, and Mamba modules via a gated mechanism; (4) adopting a Stacking two-level ensemble to merge heterogeneous discriminative evidence. Experimental results demonstrate that the Stacking ensemble achieves a validation accuracy of 85.5% on the 10-class dataset and 82.7% on the 37-class dataset, demonstrating excellent scalability and efficacy.

Key words: bird sound recognition; Mel spectrogram; MFCC; deep learning; module stitching; Stacking ensemble; bioacoustics

1 引言

1.1 研究背景

随着全球生物多样性面临严峻挑战, 传统依赖人工听辨的鸟类调查方式成本高、主观性强且难以实现全天候覆盖。自动鸟鸣识别系统可在森林、湿地、城市绿地等场景中持续采集声音数据, 并通过机器学习模型完成物种级别的自动标注, 为生态学研究提供大规模、

可复现的数据支撑 [1, 5]。近年来, Kaggle BirdCLEF 等公开竞赛极大推动了该领域的发展, 参赛者广泛尝试了从经典 MFCC + GMM/SVM 到深度卷积网络、循环网络乃至 Transformer 的多种建模范式 [2, 6]。

从语音识别课程的理论框架出发, 鸟鸣识别与连续语音识别 (ASR) 存在明确的对应关系: 预处理与端点检测对应音频归一化与切片; 声学特征提取对应 MFCC、Filter Bank 或学习式前端; 声学模型对应各类

神经网络分类器；而集成学习则类似于 ASR 中多系统融合（System Combination）在分类任务上的延伸 [3, 7]。因此，将语音识别领域成熟的前端设计与模型训练经验迁移至鸟鸣场景，具有明确的理论依据与工程合理性。

然而，鸟鸣信号亦具有若干特殊挑战：（1）类内差异大——同一物种的叫声包括鸣叫（call）、鸣唱（song）、告警声等子类型，时频结构差异显著；（2）类间差异小——近缘种之间频谱包络高度相似；（3）环境噪声复杂——风声、虫鸣、交通噪声与目标信号混叠；（4）数据标注成本高——野外录音的物种标签依赖专家知识。上述因素要求特征提取方案必须具备多域互补能力，分类器则需兼顾判别力与泛化性。

1.2 研究目标与内容

本课程任务的核心目标可概括为以下四点：

- 1. 构建规范化音频预处理流水线，使原始野外录音满足后续特征提取与模型训练的输入要求；
- 2. 设计多维度声学特征体系，覆盖语音识别课程所强调的倒谱、音高、能量及谱形状等描述子，并生成 Mel 谱图供深度网络使用；
- 3. 开展多方法对比实验，在 10 类子集上横向评估传统 ML 与多种 DL 架构，据此选定 Stacking 集成与模块缝合网络两条改进路线；
- 4. 在 37 类扩展设定下验证方法泛化能力，分析类别数增加对识别性能的影响，并完成结果讨论。

1.3 报告结构

第二章介绍数据集与预处理；第三章重点论述声学特征提取方案；第四章描述各类识别模型及模块缝合、Stacking 改进思路；第五章给出 10 类与 37 类实验结果及可视化分析；第六章进行讨论；第七章总结全文并展望未来工作。

2 数据集与预处理

2.1 数据集描述

实验数据来源于 BirdCLEF 风格的鸟鸣录音集合，元数据存储于 `train.csv`。原始全集包含数百种鸟类、数万条录音。考虑到课程实验的计算资源与对比实验的可控性，本研究采用分层采样策略，分别构造 10 类与 37 类两个实验子集，其统计信息如表 1 所示。

10 类子集选取样本量最多的 10 个物种，用于快速对比全部方法并确定改进方向；37 类子集要求每类至

表 1: 实验数据集统计

实验设定	类别数	训练样本	验证样本	随机基线
10 类快速对比	10	≈ 3469	≈ 744	10.0%
37 类扩展实验	37	11768	2522	2.7%

少 320 条样本，以在更大类别空间上检验方法的扩展性。数据划分采用分层随机抽样，训练集、验证集、测试集比例约为 70% : 15% : 15%，保证各物种在子集中比例一致。

2.2 音频预处理

预处理是语音识别与音频分类系统的第一道关口，其质量直接影响后续特征的可分性 [3, 8]。本项目的预处理流水线参照 ASR 前端惯例进行适配，主要步骤如下：

- （1）重采样至 32 kHz。原始录音统一重采样至 32 kHz。对应的分析带宽为 16 kHz，足以覆盖绝大多数鸟类基频及其低次谐波能量 [1]。相比语音识别常用的 16 kHz，更高采样率有利于保留短促音节的瞬态结构与高频谐波细节。
- （2）单声道化。统一转为单声道波形，降低存储与计算开销。
- （3）峰值幅度归一化。采用峰值归一化将波形缩放至 $[-1, 1]$ 区间，等效于简化版自动增益控制（AGC），使后续特征的动态范围处于统一尺度 [8]。
- （4）定长切片（5 s）。固定输入时长为 5 s：对长于 5 s 的录音截取起始段；对短录音在末尾进行零填充（zero-padding）。
- （5）数据增强。训练阶段引入 SpecAugment[9]——在 Mel 谱图上随机掩蔽连续频带与时间帧。此外还采用时间拉伸、音高微扰与加性高斯噪声等增强策略 [10]。




图 1: 验证集不同物种 Mel 频谱样例

图 1 展示了若干物种的 Mel 对数谱图。可以观察到：不同物种在时频纹理、谐波带分布上存在明显差

异。

3 声学特征提取

特征提取是语音识别系统中最核心的环节之一。经典 ASR 系统依赖 MFCC 等倒谱特征刻画声道滤波特性 [11]；现代端到端系统则往往以 Mel Filter Bank 或原始波形为输入 [12]。本项目采用「双通路特征架构」：Mel 对数谱图供卷积网络与 Transformer 使用；588 维手工声学向量供传统和集成通路使用 [7, 13]。

3.1 Mel 对数谱图（深度模型前端）

本研究对归一化波形计算 Mel 功率谱，主要参数为：FFT 窗长 2048 点、帧移 512 点（32 kHz 下约 16 ms 帧移）、Mel 滤波器 128 维、频率范围 20 Hz ~ 16 kHz。功率谱经对数压缩（power_to_db）后作为深度模型的输入。其等价于 Filter Bank 特征的可视化形式，与 Kaldi、ESPnet 等工具链中常用的 fbank 特征在物理含义上一致 [4, 8]。

3.2 MFCC 及差分特征（倒谱域）

梅尔频率倒谱系数（MFCC）能将倒谱系数去相关 [11]。本研究提取 40 维 MFCC，并进一步计算一阶差分（ Δ -MFCC）与二阶差分（ $\Delta\Delta$ -MFCC），以捕获特征随时间的变化率。在 ASR 中，差分特征用于刻画音节边界的动态特征 [3]。对 MFCC 及其差分沿时间轴计算均值、标准差、最小值与最大值四类统计量，将变长序列压缩为固定维向量 [16]。

3.3 短时能量与过零率（时域）

短时能量（STE）反映信号在局部时间窗口内的强度；过零率（ZCR）则刻画波形穿过零点的频率，对高能量爆发式 call 以及持续 harmonic song 有良好的判别力 [3]。

3.4 音色与谱形状特征（频域）

从每帧 STFT 谱中提取谱质心、谱带宽、谱滚降、谱平坦度、谱对比度及色度特征（Chroma STFT），沿时间轴统计汇总。这些特征在语音情感识别、环境声分类中有成熟应用 [16, 17]。

3.5 基频与浊音特征（音高域）

基频（ F_0 ）对应于发声器官振动产生的最低功能频率 [1]。本研究采用 YIN 算法 [18] 或 pYIN 算法 [19] 进

行帧级 F_0 跟踪，并提取浊音帧 F_0 均值、标准差、浊音帧比例及 voicing 概率均值，用于丰富激励源特征 [3]。

3.6 节奏与 onset 特征（时域动态）

本研究基于 onset strength 包络估计全局 tempo，并通过 onset 检测器统计单位时间内的 onset 数量，用于辅助刻画音节速率与停顿模式 [20]。

3.7 特征汇总与维度

最终手工特征向量维度约为 588 维，Mel 谱图尺寸为 $128 \times T$ 。

表 2: 多维声学特征体系简表

特征域	代表特征	语音/声学意义
倒谱域	MFCC, Δ , $\Delta\Delta$	谱包络、动态变化
时域	RMS, ZCR	能量、清浊/摩擦
频域	Centroid, Chroma	谐波结构、谱形状
音高域	F_0 均值/方差	发声频率范围
节奏域	Tempo, Onset	音节速率、停顿模式

4 识别模型与改进方法

4.1 传统机器学习基线

本研究实现以下三种基线：**KNN**（基于欧式距离进行懒惰学习， $K = 5$ ）[21]；**SVM**（采用 RBF 核，寻找最大间隔超平面）[22]；**随机森林 RF**（集成多棵决策树降低方差）[23]。

4.2 深度学习模型

深度学习将 Mel 谱图视为输入来自动学习表征 [15, 24]：**BirdCNN**（采用 EfficientNet 风格的卷积 stem）[15]；**BirdCRNN**（沿时间维施加时序注意力池化 Temporal Attention Pooling）[25]；**BirdTransformer**（参照 AST[26]，建模长程时频依赖）；**BirdMamba**（引入 Mamba 状态空间模型 [27] 以线性复杂度建模长序列）；**HybridFusionNet**（三域融合网络：CNN 全局分支 + 时序卷积分支 + 手工特征分支）。

4.3 模块缝合：StitchedFusionNet

本研究提出 **StitchedFusionNet**（模块缝合网络），在共享五层卷积骨干上并行部署全局表征支路、CRNN 注意力时序支路 [25] 与 Mamba 长程时序建模支路 [27]。最后通过门控融合机制（GatedFusion）对三支路输出施

加 Softmax 权重加权求和，融合代表不同建模范式的轻量子模块。

4.4 Stacking 二级集成

Stacking 是一种两层集成策略 [28]。第一层中，深度模型以 Mel 谱图 + 手工特征为输入，SVM 以 588 维手工特征为输入，分别独立训练并输出概率向量；第二层以第一层的输出拼接并标准化后作为输入，由多项 Logistic Regression 元学习器进行决策融合。这类类似于 ASR 中多系统 ROVER 融合的思想 [29]。

5 实验设计与结果分析

5.1 实验协议与训练动态分析

实验评价指标包括：Top-1 准确率（Accuracy）、Macro- F_1 、Top-3 与 Top-5 准确率。深度模型训练采用 AdamW 优化器、余弦退火学习率调度、Focal Loss[30] 与标签平滑。

深度模型的训练动态（以 CRNN 为代表，见图 2）揭示了实验协议中的若干细节。训练损失在前 5 ~ 10 个 epoch 内快速下降，验证 Macro- F_1 在约 15 ~ 20 epoch 后进入平台期；若继续延长训练，验证指标波动幅度增大，提示在小样本、多类别设定下存在过拟合风险。本研究采用的早停策略、余弦退火学习率与 SpecAugment 数据增强，正是为了在「充分拟合」与「保持泛化」之间取得平衡。




图 2: CRNN 训练损失与验证 Macro- F_1 收敛曲线

5.2 十类物种全方法对比

表 3 给出 10 类设定下各方法在验证集上的完整对比结果。可以观察到：(1) 传统 ML 中 SVM 显著优于 KNN 与 RF，验证了 588 维手工特征的可分性；(2) 深度模型整体优于传统 ML，CNN 以 84.1% 居 DL 单一模型前列；(3) Stacking (CNN + SVM) 以 85.5% 准确率和 98.8% Top-5 准确率取得最优。

从直观的对比图（图 3）可以更清晰地看到三类方法之间的性能梯度：传统 ML 整体落在 50% ~ 70% 区间，深度模型集中在 80% ~ 84% 区间，而 Stacking 在 Top-1 与 Top-5 两个维度上均形成明显「台阶」。

表 3: 10 类物种验证集全方法对比 (%)

方法	类型	准确率	Macro- F_1	Top-5
KNN	传统 ML	49.5	49.4	80.9
SVM	传统 ML	68.3	68.4	93.8
随机森林 RF	传统 ML	59.7	59.4	89.7
CNN	深度学习	84.1	84.2	96.1
CRNN	深度学习	82.4	82.4	96.1
Hybrid 融合	深度学习	80.9	80.9	96.1
Mamba	深度学习	83.7	83.7	95.2
Transformer	深度学习	79.6*	79.2*	95.5*
Stitch 模块缝合	深度·创新	81.8*	81.5*	95.9*
Stacking (CNN+SVM)	集成融合	85.5	85.5	98.8

* 注：Transformer/Stitch 为同配置全量实验归档值。




图 3: 10 类设定下各方法准确率与 Top-5 对比

5.3 方法选型

基于上述实验结果，本研究选定两条主线进入 37 类扩展实验：**Stacking 集成**（验证集最优，Top-5 接近 99%）与 **StitchedFusionNet**（结构创新，单模型端到端且可解释性好）。选型逻辑可概括为「性能优先 + 结构创新」双轨并行。

表 4: 选定改进方案对比

方案	核心机制	10 类 Acc	选型依据
Stacking 集成	深度 + SVM 概率融合	85.5%	验证集最优
StitchedNet	多时频子模块缝合	≈81.8%	结构创新性

5.4 三十七类扩展实验及误差分析

将类别数从 10 扩展至 37 后，随机猜测基线由 10% 降至 2.7%，类间决策边界数量急剧增加。表 5 汇总了代表性方法在完整验证集上的结果。

横向对比可见，单一深度模型中，Hybrid (72.8%) 显著优于 CRNN (56.2%) 与 Stitch (61.1%)。而 Stacking (Hybrid + SVM) 以 82.7% Top-1、83.0% Macro- F_1 取得

表 5: 37 类物种验证集主要结果 (%)

方法	准确率	Macro-F ₁	Top-3	Top-5
KNN	29.4	29.3	43.9	52.7
SVM	50.2	50.2	68.8	76.3
CRNN	56.2	56.2	73.5	79.6
Stitch (50 ep)	61.1	61.5	77.0	82.3
Hybrid (50 ep)	72.8	73.1	84.4	87.9
Stacking (Hybrid+SVM)	82.7	83.0	95.0	97.4

最优。图 4 展示了该方案的多指标摘要，其 Top-3 达 95.0%、Top-5 达 97.4%。




图 4: 最优 Stacking 模型指标摘要 (37 类)

为理解剩余约 17% 的 Top-1 误差来源，对验证集混淆矩阵 (图 5) 进行分析。行归一化后可以看出，误判并非均匀分布，而是集中在声学模式相近的近缘种之间——例如截载频范围或音节重复频率相似的物种对。Stacking 集成后，元学习器在概率域实现了有针对性的修正，使得对角线整体显著增强。




图 5: 主要鸟种混淆矩阵 (行归一化)

6 讨论

6.1 特征互补性与 Stacking 增益

在 37 类实验中，SVM 准确率为 50.2%，Hybrid 达 72.8%，而将二者融合的 Stacking 则达到了 82.7%。这种融合增益约 10 个百分点，且显著超过了“取较好单模型”的上界。该现象强有力地证明了，两类基学习器所依赖的表征空间具有实质性差异。

从特征的物理意义来看，Mel 谱图通路通过卷积层提取二维时频局部纹理，对能量调制形态敏感；而 SVM 所利用的手工特征，则更接近语音识别传统前端所强调的声道与激励源参数化描述 [3, 11]。二者的低相关性使得它们决策边界互补 [7]，类似于 ASR 发展史上“深度神经网络声学模型 + GMM 超向量/i-vector 后端”的经典组合 [13]。元学习器在概率域实现了数据驱动的 ROVER 式融合 [29]，从而对高混淆物种样本给予了更细粒度的纠偏。

6.2 模块缝合网络的优劣

StitchedFusionNet 在 37 类下准确率降至 61.1%，未能超越简洁的 Hybrid 架构。这提示了我们在特定数据规模与训练预算下的结构设计权衡。

一方面，模型复杂度与优化难度的失衡是核心诱因。Stitch 在共享骨干上并行部署全局池化、时序注意力与 Mamba 三支路，其高自由度的门控机制在小样本前提下极易出现过拟合，需要更长的训练周期与更精细的学习率微调。另一方面，Mamba 支路对混合精度训练 (AMP) 的数值敏感性，也增大了其优化景观的粗糙度。然而，Stitch 所体现的“可复用子模块自适应融合”思想，与 ASR 中的 Conformer (将卷积局部建模与 Transformer 全局注意力缝合于同一层块) 在方法论上是完全相通的 [31]。本实验结果应视为阶段性评估，而非对多范式缝合方向的否定。

6.3 类别扩展与泛化分析

从 10 类扩展到 37 类，随机猜测基线从 10% 骤降至 2.7%，而 Stacking 的 Top-1 准确率仅微幅下降了 2.8 个百分点 (从 85.5% 到 82.7%)。这说明本研究构建的多模态特征与集成策略在类别空间扩展时表现出了卓越的可扩展性 (Scalability)。

更具有实际生态监测意义的是 Top-k 指标的表现。37 类设定下，Stacking 的 Top-3 和 Top-5 准确率分别达到了 95.0% 和 97.4%。在野外声景记录的大规模自动监测场景中，系统往往以“AI 自动给出短列表 + 领域专家终审”的方式进行部署 [2]。Top-5 接近 97% 的性

能，意味着绝大多数录音片段均能将真实物种压缩在五个选项之内，从而在大幅削减一线人员听辨负担的同时，将系统误判风险控制在极低水平。

6.4 与语音识别课程知识的对应

本项目的管线设计完整走通了语音识别课程中的核心技术链路。若将课程章节与项目模块进行映射，其对应关系为：波形预处理对应预加重、静音裁剪与定长切片；声学特征提取对应 MFCC 与 Mel 滤波器组设计；多分支声学建模对应神经网络建模；系统组合则对应集成学习理论 [3, 7]。

从任务的本质形态来看，鸟鸣识别可以抽象为无词典约束、无语言模型的闭集关键词检测（Keyword Spotting）。它与 ASR 中的语音唤醒、非语音声学事件检测在工程逻辑上高度同构。课程中强调的端点检测、特征归一化以及 SpecAugment 数据增强 [9] 在本项目中均得到了成功的复现与检验，这表明生物声学并非孤立的技术域，而是语音处理方法论的自然延伸。

6.5 局限与改进方向

尽管本研究所构建的双通路 Stacking 集成系统在 37 类任务上取得了优异的指标，但在面向更复杂的野外真实声景部署时，仍显现出若干亟待克服的局部局限。首先，在时域序列建模方面，当前采用的定长 5 s 硬切片机制虽然保证了批量矩阵运算的规范性，但往往会截断部分长时鸣唱（song）的完整音节序列，且未能有效捕捉一轮鸣叫中音节重复的长程上下文韵律依赖。未来的改进路线应当考虑引入自适应多尺度窗口切片或基于注意力机制的片段级标签聚合。其次，针对野外复杂环境中的风雨、虫鸣和交通噪声干扰，系统目前高度依赖谱减法与 SpecAugment 频域掩蔽 [9]，其在低信噪比下的抗噪表现仍有提升空间，后续可考虑引入对环境动态范围压缩更鲁棒的每通道能量归一化（PCEN）前端 [32]。

此外，从表征学习与生态真实性的宏观视角审视，本项目的方​​法论边界主要局限于监督学习框架内。由于未充分利用野外海量的未标注声音数据，模型在类别进一步扩展时可能面临真阳性标签匮乏的瓶颈，这与现代 ASR 所强调的“大规模无监督预训练（如 wav2vec 2.0[33]）+ 小样本有监督微调”范式仍存在代差。同时，当前的闭集分类假设不符合自然生境中存在大量未知干扰物种的客观现实。在后续的演进中，系统必须从纯粹的闭集分类器转向具备自适应置信度校准与未知物种拒识（Out-of-Distribution, OOD）能力的上线级监测组件，从而真正融入生态学分类体系。

7 结论

本报告针对鸟类鸣声识别任务，在语音识别课程理论框架下设计并走通了完整的技术管线。实验结果表明，涵盖倒谱、时域、频域音色、音高与节奏的多维手工特征，能与深度学习 Mel 谱图通路形成强烈的判别互补。基于此构建的 Stacking 二级集成策略在 37 类扩展任务上实现了 82.7% 的 Top-1 准确率与 97.4% 的 Top-5 准确率。本研究成功验证了语音识别成熟的前端与建模理论在生物声学交叉领域的泛化能力与应用价值。

参考文献

- [1] STOWELL D, SUEUR J, et al. Automatic acoustic detection of birds: A brief review [J]. *Ibis*, 2019, 161(4): 874-883.
- [2] GOËAU H, KAHL S, et al. Overview of BirdCLEF 2021: Bird call identification in soundscape recordings [C]. CLEF Working Notes, 2021.
- [3] RABINER L, JUANG B. *Fundamentals of Speech Recognition* [M]. Prentice Hall, 1993.
- [4] POVEY D, et al. The Kaldi speech recognition toolkit [C]. IEEE ASRU, 2011.
- [5] KAHL S, et al. BirdNET: A deep learning solution for avian diversity monitoring [J]. *Ecological Informatics*, 2021, 61: 101236.
- [6] LOSTANLEN V, et al. Learning the helix topology of musical pitch [C]. ICASSP, 2018.
- [7] HINTON G, et al. Deep neural networks for acoustic modeling in speech recognition [J]. *IEEE Signal Processing Magazine*, 2012, 29(6): 82-97.
- [8] YOUNG S, et al. *The HTK Book* (Version 3.4) [M]. Cambridge University, 2006.
- [9] PARK D S, et al. SpecAugment: A simple data augmentation method for automatic speech recognition [C]. Interspeech, 2019.
- [10] KO T, et al. Audio augmentation for speech recognition [C]. Interspeech, 2015.
- [11] DAVIS S, MERMELSTEIN P. Comparison of parametric representations for monosyllabic word recognition [J]. *IEEE TASSP*, 1980, 28(4): 357-366.

- [12] HINTON G, et al. A fast learning algorithm for deep belief nets [J]. *Neural Computation*, 2006, 18(7): 1527-1554.
- [13] DEHAK N, et al. Front-end factor analysis for speaker verification [J]. *IEEE TASLP*, 2011, 19(4): 788-798.
- [14] STEVENS S S, VOLKMANN J, NEWMAN E B. A scale for the measurement of the psychological magnitude pitch [J]. *JASA*, 1937, 8(3): 185-190.
- [15] HERSHEY S, et al. CNN architectures for large-scale audio classification [C]. ICASSP, 2017.
- [16] PEETERS G. A large set of audio features for sound description [R]. IRCAM, 2004.
- [17] SCHULLER B, et al. Speech emotion recognition: Two decades in a nutshell [J]. *Computer Speech & Language*, 2018.
- [18] DE CHEVEIGNÉ A, KAWAHARA H. YIN, a fundamental frequency estimator for speech and music [J]. *JASA*, 2002, 111(4): 1917-1930.
- [19] MAUCH M, DIXON S. pYIN: A fundamental frequency estimator using probabilistic threshold distributions [C]. ICASSP, 2014.
- [20] BELLO J P, et al. A tutorial on onset detection in music signals [J]. *IEEE TASLP*, 2005, 13(8): 1035-1047.
- [21] COVER T, HART P. Nearest neighbor pattern classification [J]. *IEEE TIT*, 1967, 13(1): 21-27.
- [22] CORTES C, VAPNIK V. Support-vector networks [J]. *Machine Learning*, 1995, 20(3): 273-297.
- [23] BREIMAN L. Random forests [J]. *Machine Learning*, 2001, 45(1): 5-32.
- [24] LECUN Y, et al. Gradient-based learning applied to document recognition [J]. *Proceedings of the IEEE*, 1998, 86(11): 2278-2324.
- [25] CHOROWSKI J, et al. Attention-based models for speech recognition [C]. NeurIPS, 2015.
- [26] GONG Y, et al. AST: Audio Spectrogram Transformer [C]. Interspeech, 2021.
- [27] GU A, DAO T. Mamba: Linear-time sequence modeling with selective state spaces [C]. COLM, 2024.
- [28] WOLPERT D H. Stacked generalization [J]. *Neural Networks*, 1992, 5(2): 241-259.
- [29] YOUNG S. A review of large-vocabulary continuous-speech recognition [J]. *IEEE Signal Processing Magazine*, 1996, 13(5): 45-57.
- [30] LIN T Y, et al. Focal loss for dense object detection [C]. ICCV, 2017.
- [31] GULATI A, et al. Conformer: Convolution-augmented Transformer for speech recognition [C]. Interspeech, 2020.
- [32] LOSTANLEN V, et al. Per-channel energy normalization: Why and how [J]. *IEEE SPL*, 2019, 26(1): 39-43.
- [33] BAEVSKI A, et al. wav2vec 2.0: A framework for self-supervised learning of speech representations [C]. NeurIPS, 2020.

作者简介:



骆俊杰, 2023 级本科生, 南京师范大学计算机与电子信息学院/人工智能学院人工智能专业, 主要研究方向为音频信号处理、序列深度学习与生物声学监测。

E-mail: 19230441@njnu.edu.cn